



Firas Bennani

France - mobile

+21629795430

firas.bennani29@gmail.com

<https://www.linkedin.com/in/firas-bennani-a57482160/>

Experience

SBcom
responsable de Web Developpement
juin 2025-Sepetmebre 2026
Bizerte

- Python, javascript et LangChain pour Backend
- Gradio pour le Frontend

EXDEV
responsable de développement informatique
septembre 2024- Juin 2025
Bizerte

- devloppement en langague python, c++ et c#
- gestions de data avec Power BI et excel
- creation des sites web

Education

ENSTAB
Technologies avancées
Septembre 2025 - présent
Cycle ingénieur

ESSTHS
Math physique
Septembre 2023- Juillet 2025
Cycle préparatoire

Lycée pilote Bizerte
Math
3.4 scale 4
Septembre 2019 - Aout 2023
secondaire

Langues

French
TCF C1

English
TOEFEL C1

Volunteering

ACM ENSTAB
vice president
September 2025
ENSTAB

youth club LPBizerte
external vice president
September 2019
Lycée pilote bizerte

JCI Zarzouna
General Secretary
June 2019
Zarzouna Bizerte

résumé

A la recherche d'un **stage d'été** dans le poste d'ingénieur en intelligence artificielle à partir de juin 2026 et pour une durée de 3 mois.

Etudiant 1ère année en cycle ingénieur en technologies avancées à ENSTAB, spécialisé en intelligence artificielle et la data science, avec une capacité à bien entrainer des machines pour votre service et bien optimiser la data pour une exploitation plus idéale.

Projects

Pipeline d'évaluation RAG (LLM-as-a-Judge) **Février 2026**
agent RAG

pipeline production-ready évaluant automatiquement la qualité des réponses via un LLM juge : orchestration avec LangChain/LCEL, stockage vectoriel FAISS, optimisation de récupération (LongContextReorder), interface Gradio. Tech : llama-3.1-8b-instruct (judge), llama-3.2-nv-embedqa-1b-v2 (embeddings), embeddings, vector store, retrieval, evaluation

construction d'un modèle de reconnaissance de fruits **January 2026**
Deep learning model

Développement d'un modèle de reconnaissance de fruits basé sur l'architecture VGG16 (torchvision) . En combinant le Transfer Learning et des techniques de Data Augmentation, j'ai optimisé le pipeline de traitement pour atteindre un score de précision de 95 % sur le jeu de validation

Certifications

getting started with deep learning NVIDIA **Janvier 2026**
NVIDIA

- conception et entraînement de CNN pour la classification d'images ; Transfer Learning et fine-tuning ; modélisation séquentielle (RNN/LSTM) pour séries temporelles ; augmentation de données et déploiement de modèles.

Fundamentals of Accelerated computing with CUDA python NVIDIA **February 2026**
NVIDIA

- JIT (Numba), accélération GPU de NumPy, gestion CPU - GPU, kernels CUDA personnalisés, fondamentaux de programmation parallèle.

Building LLM Applications With Prompt Engineering **février 2026**
NVIDIA

- LangChain Expression Language (LCEL) — conception de chains et d'agents, tool-calling, extraction de données structurées via Pydantic / JsonOutputParser pour applications IA scalables.

Introduction to Transformer-Based Natural Language Processing **février 2026**
NVIDIA

- text classification ; token classification ; questions answering ; transfer learning ; fine tuning

Rapid Application Development with Large Language Models (LLMs) **Février 2026**
NVIDIA

- LLM, Generative AI, Transformers (encoder/decoder), Multimodal, Orchestration / Agentic (LangChain, LangGraph), Prompt engineering, évaluation, déploiement.

Building RAG Agents with LLMs **Février 2026**
NVIDIA

- RAG, Retrieval-Augmented Generation, LangChain, Documents, Embeddings, Vector Stores, FAISS, indexation vectorielle, prompt engineering, Gradio, LangServe, évaluation, déploiement production.

Generative AI with Diffusion Models **Février 2026**
NVIDIA

- Diffusion models, DDPM, U-Net, Classifier-Free Guidance, CLIP, text-to-image pipelines, optimisations, génération d'images haute fidélité, entraînement et inférence.

Skills

Agents & RAG

LangChain, RAG, Retrieval-Augmented Generation, Embeddings, Vector stores, FAISS, document loaders, indexation vectorielle, orchestration agentique, LangServe, Gradio, agents autonomes

SQL

Optimisation de pipelines de données complexes via Window Functions et CTEs, réduisant les temps de traitement de 40%. Conception d'architectures en schéma en étoile pour l'analyse BI et gestion de datasets massifs sous PostgreSQL avec stratégies d'indexation avancées

Prompt engineering & NLP

prompt engineering, chaîne de prompts, extraction structurée (Pydantic/JSON), classification texte, systèmes QA, fine-tuning, tokenization, Transformers (Hugging Face)

Modèles génératifs (texte & image)

LLMs, Transformers (encoder/decoder), Diffusion (DDPM, U-Net), Classifier-Free Guidance, CLIP, text-to-image, pipelines multimodales

Deep Learning & Vision

PyTorch, CNN, transfer learning, data augmentation, détection/segmentation, RNN/LSTM pour séries temporelles

Calcul accéléré & optimisation

CUDA Python, Numba, optimisation GPU, mixed precision (AMP), entraînement distribué (DDP), profilage/perf

MLOps & déploiement production

mise en production de modèles, Docker, FastAPI, CI/CD, monitoring, tests A/B, évaluation rigoureuse (accuracy, F1, recall, BLEU, perplexity)

Outils & bibliothèques

PyTorch, TensorFlow, Hugging Face, scikit-learn, pandas, NumPy, FAISS, LangGraph, Gradio, Git

languages

Python/ Java / JavaScript /c/ c++ / c#

conception avec UML

conception des bases de données et des projets avec UML